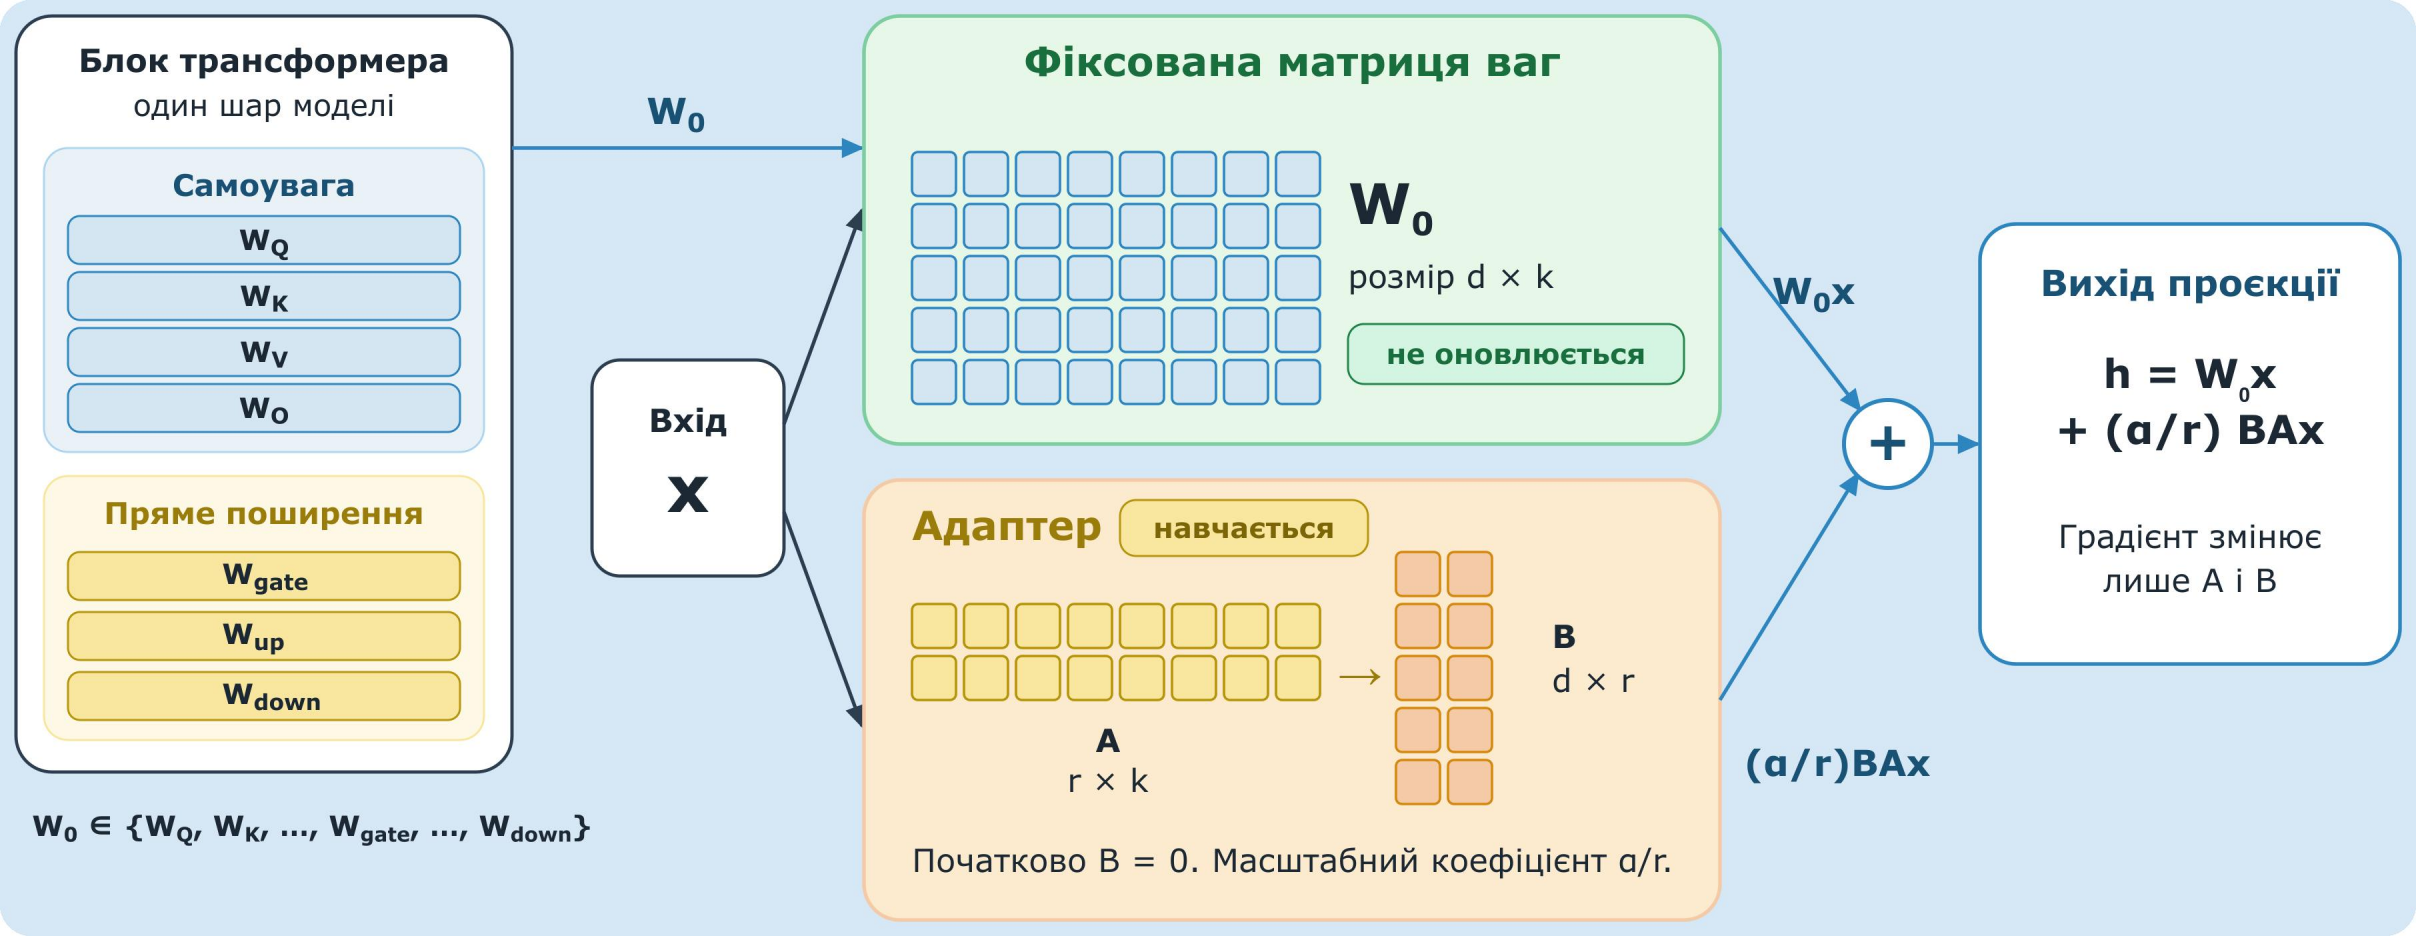

Блок трансформера
один шар моделі
Самоувага
W_Q
W_K
W_V
W_O
Пряме поширення
W_{gate}
W_{up}
W_{down}
$W_0 \in \{W_Q, W_K, \ldots, W_{gate}, \ldots, W_{down}\}$
W_0
Вхід
x
Фіксована матриця ваг
W_0
розмір d × k
не оновлюється
Адаптер
навчається
A
r × k
B
d × r
Початково B = 0. Масштабний коефіцієнт α/r.
W_0x
$(\alpha/r)BAx$
+
Вихід проєкції
$h = W_0x + (\alpha/r)\,BAx$
Градієнт змінює лише A і B